

Задача обучения с учителем

Обучение с учителем — это один из основных типов задач машинного обучения. Цель состоит в том, чтобы на основе примеров построить модель, которая по новым входным данным предсказывает правильный ответ. В отличие от обучения без учителя, где используются только входные данные, в обучении с учителем каждому обучающему примеру сопоставлен известный правильный ответ, называемый меткой или целевой переменной.

Исходные данные представляются в виде набора объектов. Каждый объект описывается набором признаков. Признаки могут быть числовыми, категориальными или текстовыми. Совокупность признаков одного объекта называется вектором признаков. Множество всех примеров делится как минимум на две части: обучающую выборку и тестовую выборку. На обучающей выборке модель настраивает свои параметры, а на тестовой выборке оценивается ее качество. Для более надежной оценки часто используется кросс-валидация, при которой данные многократно разбиваются на обучающую и проверочную части.

Внутри задачи обучения с учителем выделяют два основных класса задач. Первый — это классификация, в которой целевая переменная принимает значения из конечного множества классов. Классификация бывает бинарной, когда классов всего два, и многоклассовой. Второй класс задач — регрессия, в которой целевая переменная является непрерывной числовой величиной. Например, предсказание того, является ли письмо спамом — это задача классификации, а предсказание цены квартиры — задача регрессии.

Для решения этих задач применяются различные алгоритмы. К классическим алгоритмам относятся линейная регрессия, логистическая регрессия, метод k ближайших соседей, решающие деревья, случайный лес и метод опорных векторов. Для сложных задач с большими объемами данных используются искусственные нейронные сети. Каждый алгоритм имеет внутренние параметры, которые настраиваются во время обучения, и гиперпараметры, которые задаются до обучения и подбираются отдельно.

Процесс обучения состоит в том, что алгоритм минимизирует функцию потерь, которая измеряет расхождение между предсказаниями модели и истинными ответами на обучающей выборке. Для задач регрессии часто используется среднеквадратичная ошибка, а для задач классификации — кросс-энтропия.

Качество обученной модели оценивается с помощью метрик. Для классификации применяются точность, полнота, precision и F1-мера. Для регрессии используются средняя абсолютная ошибка, среднеквадратичная ошибка и коэффициент детерминации. Важно различать качество модели на обучающей и тестовой выборке: если модель показывает высокое качество на обучении и низкое на тесте, это называется переобучением. Противоположная ситуация, когда модель плохо работает и на обучении, и на тесте, называется недообучением. Борьба с переобучением ведется с помощью регуляризации, увеличения объема данных и упрощения модели.